

1 Einführung

Willkommen zu meiner Presentation mit dem Titel “Generierung von Schachkommentaren mittels maschinellem Lernen”.

Zu Beginn werde ich Ihnen einen Überblick darüber geben, wie die Themen Schach und künstliche Intelligenz zusammenhängen, damit die Notwendigkeit meiner Forschungsfrage deutlich wird. Dann werde ich kurz den Aufbau zur Lösung der Forschungsfrage vorstellen.

In den Abschnitten 2 und 3 wird der Aufbau näher erläutert, und Abschnitt 4 schließt die Präsentation mit einem Fazit ab.

2 Überblick

Schach gehört zu einem der am längsten erforschten Themen der Künstlichen Intelligenz. Das liegt vor allem daran, dass Pioniere der KI wie Alan Turing Schachspieler waren und das Schachspiel als ideales Modell für maschinelles Lernen betrachteten.

Damals wie heute wurde hauptsächlich auf dem Gebiet der Schachengines geforscht. Das sind Schachprogramme. Das Ziel der Forschung ist es, die Spielstärke zu optimieren. Heute liegt die Spielstärke der Engines weit über der der besten Profispieler.

Ein Problem ist, dass dieses hohe Spielniveau zu einer Intransparenz von Zügen bzw. Zugfolgen führt. Das bedeutet, dass man professionelle Spieler oder Kommentatoren braucht, um die Ideen hinter den Zügen des Computers zu verstehen, und selbst deren Analysen sind nicht immer korrekt.

Meine Forschungsfrage "Wie kann maschinelles Lernen genutzt werden, um Kommentare zu Schachpartien zu generieren?" versucht, dieses Problem der Intransparenz von Zügen zu lösen, indem versucht wird, menschliche Kommentatoren durch virtuelle zu ersetzen. Außerdem können Kommentare nicht nur für Partien von Schachengines, sondern auch für menschliche Partien erstellt werden, so dass die eigene Spielstärke verbessert werden kann.

Um die Forschungsfrage zu lösen, wird sie dazu in zwei Teile aufgeteilt. Zum einen die Informationsbeschaffung und zum anderen die Kommentarerstellung. Die Informationsbeschaffung befasst damit *woher* man die Informationen bekommen die zum übersetzen nötig sind. Die Kommentargenerierung nimmt diese Informationen und beschäftigt dann damit *wie* und *was* für Kommentare erzeugt werden sollen.

Für den ersten Teil wird eine bereits erwähnte Schach Engine verwendet, für den zweiten Teil das sogenannte Encoder-Decoder-Modell.

3 Schach Engine

Wie bereits erwähnt, sind Engines Programme zum Schachspielen. Damit diese funktionieren, müssen sie eine Reihe von Anforderungen erfüllen. Diese sind die

- Brett Darstellung
- Zugsuche
- Positionsbewertung

Der Vorteil von Schachengines ist, dass diese Anforderungen genau die Informationen bereitstellen, die später benötigt werden.

3.1 Brett Darstellung

Für den Computer muss das Schachbrett und die Figuren in eine verarbeitbare Form gebracht werden.

Eine Standardimplementierung sind sogenannte Bitboards.

Jedes Feld kann entweder den Wert 0 oder 1 haben, wobei 0 bedeutet, dass sich keine Figur auf dem Feld befindet, und 1, dass ein Feld belegt ist.

Für jeden Figurentyp, Figurenfarbe und für die Rochade werden Bitboards erstellt. Für die Leute die nichts mit dem Begriff Rochade anfangen können, dabei handelt es sich um einen speziellen Spielzug, um den König in eine sichere Position zu bringen.

Die Anzahl der Bitboards können sich je nach Implementierung variieren. Hier sind es insgesamt 16.

Eine mögliche Implementierung sind 8×8 Arrays. Es gibt jedoch auch andere Implementierungen, z.B. mit einem eindimensionalen Array oder als Objekte.

Hier habe ich als Beispiel ein Bitbrett für die weißen Bauern mitgebracht. Durch das "Übereinanderlegen" der verschiedenen Bitboards können die Züge mit Hilfe logischer Operationen berechnet werden.

Ein Vorteil dieser Darstellung ist, dass sie als Input für neuronale Netze verwendet werden kann. Ich werde Ihnen gleich zeigen, wie das aussieht.

3.2 Zugsuche und Positionsbewertung

Schach ist bisher ein ungelöstes Spiel, d.h. es ist nicht bekannt, ob es eine Methode gibt, die immer zum Sieg oder, wenn sie von beiden Seiten angewendet wird, zum Unentschieden führt.

Deshalb basiert die Qualität der Suche nach Zügen und der Bewertung immer auf der Programmierung der Engine und Rechenleistung des Systems.

Bekannte Implementierungen, die keine Methoden des maschinellen Lernens enthalten, sind der MiniMax-Algorithmus bzw. die Erweiterung Alpha-Beta Pruning für die Zugsuche und eine handgeschriebene Bewertungsfunktion.

Die Implementierung, die ich euch zeigen werde, basiert auf maschinellem Lernen. Sie verwendet einen Monte-Carlo-Suchbaum für die Zugsuche und ein neuronales Netz für die Positionsbewertung.

Der Ansatz basiert auf der AlphaZero-Engine, die zum ersten Mal in der Lage war, die stärksten bekannten Engines zu schlagen, die ohne maschinelles Lernen arbeiten.

Wie genau der Ansatz funktioniert erkläre ich an einer Abbildung.

1. Wir haben eine Position, diese liegt ich erzählt habe in der BitBoard Darstellung vor.
2. Die Codeierte Position wird als Input für ein neuronales Netzwerk verwendet, welche die Position bewertet. Als Output gibt dieser eine Bewertung (hier v) aus und Wahrscheinlichkeiten für folgende Züge (hier p_1 bis p_3 für drei Züge).
3. Der Monte Carlo Suchbaum, generiert dann alle möglichen legalen Züge.
4. Der ursprüngliche Position wird dann die Bewertung v zugeordnet und die berechneten Zügen bekommen die Zugwahrscheinlichkeiten p . Der Suchbaum wählt dann Pfade, teils zufällig, aus, simuliert Partien und bewerte all diese Positionen und Züge mit Hilfe des Neuronalen Netzwerks.
5. Für alle Pfade werden Gesamtstatistiken erstellt und der Pfad mit der besten Gesamtstatistik wird gespielt.

Damit das Neuronale Netzwerk zuverlässige Bewertungen erzeugt muss es trainiert werden. In traditionellen Engines wurde Trainingsdaten, aus Datenbanken, welche Profipartien speichern, benutzt. Die Daten können allerdings auch durch Selbstspiel generiert werden.

Dabei existiert Anfangs eine Engine besteht aus den Spielregeln, einem untrainiertes neuronales Netz und der MCTS-Algorithmus

Um das Netzwerk zu trainieren werden nun 4 Schritte immer wieder wiederholt.

1. Das Programm spielt gegen sich selbst, zeichnet jede Partie auf und weißt dann einer Partie verloren, unentschieden oder gewonnen zu.
2. Das Neuronale Netzwerk wird geklont und bekommt die Partien, zusammen mit dem Wert, um die Parameter anzupassen
3. Das Programm mit dem neuem Neuronale Netzwerk spielt dann gegen das alte Programm
4. Das Programm das gewinnt wird dann ausgewählt und es geht von vorne los

Durch diese Trainingsmethode konnte die damals beste Engine *Stockfish*, in nur 4 Stunden übertroffen werden.

Aber welche Informationen haben wir nun von der Engine bekommen.

Zum einen haben wir eine verarbeitbare Brettdarstellung. Außerdem können wir erkennen, ob eine Stellung gut oder schlecht ist, und wissen anhand der Zugwahrscheinlichkeiten, was gute und schlechte Züge sind. Darüber hinaus können wir Zugpfade nehmen, um die Absicht hinter einer Strategie in einer Partie zu bestimmen oder Züge zu vergleichen.

4 Schachkommentator

Jetzt werden ich den Teil besprechen, der für die Erzeugung von Kommentaren verantwortlich ist.

4.1 Encoder-Decoder Modell

Die Erzeugung von Kommentaren fällt in den Bereich der Sequenz-zu-Sequenz-Verarbeitung, was bedeutet, dass ein Input (hier entsprechende Informationen) auf einem Output (d.h. menschliche Sprachen) dargestellt wird. Länge von Input und Output können sich dabei unterscheiden.

Eine Architektur die dies ermöglicht ist das Encoder-Decoder Modell.

Das Modell basiert auf einer speziellen neuronalen Netzwerkarchitektur, der so genannten bidirektionalen Long-Short Term Memory-Architektur. Bevor ich das Encoder-Decoder Modell erkläre, gehe ich kurz auf diese Architektur ein.

LSTMs sind eine Erweiterung von Rekurrenten Neuronalen Netzwerken

RNNs sind neuronale Netze, die zur Verarbeitung von Sequenzen geschaffen wurden. Dabei werden die generierten Outputs wieder mit neuem Input in das Netzwerk geben. Der Zustand des Netzes repräsentiert die Neuronen also zu einen bestimmten Zeitpunkt. Durch das zurückführen des Outputs kann sich das Netzwerk an laufende Muster erinnern und entsprechend darauf reagieren.

Bidirektionale RNNs sind eine Erweiterung der RNNs. Eingaben werden nicht nur in positiver Zeitrichtung, sondern auch in negativer Zeitrichtung berücksichtigt. D.h. es werden sowohl die vorherigen als auch die nachfolgenden Eingabedaten einbezogen.

Ein Problem, das bei RNNs auftritt, ist, dass sie sich zwar länger laufende Muster merken können, dieses Gedächtnis aber Probleme mit langen Sequenzen hat. Dieses Problem wird als das Problem des verschwindenden Gradienten bezeichnet. LSTMs sind spezielle Neuronen, die dieses Problem lösen. Sie verfügen über ein Kurzzeitgedächtnis und ein Langzeitgedächtnis, so dass die Muster auch bei langen Sequenzen genau gespeichert werden.

Bidirektionale LSTMs sind also bidirektionale RNNs, die die Long-Short Term Memory Neuronen verwenden.

Das Encoder-Decoder Modell besteht aus zwei Teilen dem Encoder, Decoder. Bei beiden handelt es sich um Bidirektionale LSTMs.

Der Encoder empfängt als Input die Informationen von der Schach-Engine und wandelt sie in eine andere Darstellung um. Diese Darstellung ist eine Zusammenfassung der Informationen. Die Zusammenfassung wurde mit Hilfe eines Aufmerksamkeitsmechanismus erstellt.

Der Decoder verwendet dann diese Darstellung und erstellt entsprechende Kommentare.

Hier habe ich eine Abbildung so eines Encoder-Decoder Modells mitgebracht.

Eine dieser Blöcke stellt das Netzwerk zu einem bestimmten Zeitpunkt dar, von links nach rechts werden zeitlich aufsteigend die entsprechenden Sequenz eingegeben.

Die Hidden Layers verarbeiten die Sequenz und durch einen Aufmerksamkeitsmechanismus werden bestimmte Teile der Eingabe zusammengefasst und zu einem Endzustand kombiniert. Dieser Zustand wird auch als Kontextvektor bezeichnet.

Der Kontextvektor wird dann zur Initialisierung der Neuronen des Decoders verwendet. Um Kommentare zu erzeugen, wird ein Startzeichen als Eingabe eingegeben, und die Ausgabe stellt den erzeugten Kommentar dar. Die Ausgabe wird als neue Eingabe in den Decoder gegeben. Dies geschieht so lange, bis ein Endzeichen erreicht wird, das das Ende des Kommentars signalisiert.

Um zu wissen zu was genau man Kommentare generieren soll, wurde 5 Kategorien festgelegt.

Das Problem ist, dass es für Encoder-Decoder Modell nicht ausreicht. Deshalb wird für jede dieser Kategorien ein Encoder-Decoder Modell verwendet welche sich im Training unterscheiden. Die Kategorien, werden deshalb auch Generationsmodelle genannt.

Das Training der Generationsmodelle unterscheiden sich in der Merkmalen die diese zum Trainieren bekommen sowie die Anzahl der Züge.

Encoder die mehrere Züge bekommen werden dabei als Multi-Move-Encoder bezeichnet, Encoder die nur einen Zug bekommen als Single-Move-Encoder.

Welche Merkmale die Modelle erhalten, lässt sich als Funktion zusammenfassen. Ein Zug wird dabei mit m für move abgekürzt und eine Position mit b für board.

Nun da man weiß was für Merkmale man zum trainieren brauch, wurden Datensätze zum Trainieren, erstellt, welche basierend auf Kommentaren aus den fünf Kategorien aus einem Schachforum stammen.

5 Fazit

Schließlich noch das Fazit. Generell lässt sich sagen, dass die Forschungsfrage zur Generierung von Schachkommentaren zwar beantwortet werden konnte, sie aber den Menschen noch nicht ersetzen kann. Die generierten Kommentare konnten in verschiedenen Verfahren zur Messung der Genauigkeit gute Ergebnisse erzielen, menschliche Kommentatoren können allerdings noch deutlich tiefere Einblicke geben.

Dennoch bietet der vorgestellte Ansatz eine gute Grundlage für weitere Forschungen.